КЕЙС

Модель маркетплейса: от корзины до выкупа

Capibara - маркетплейс из Сан-Паулу

За два года, с сентября 2016 по октябрь 2018, площадка выросла от сотен заказов в месяц до семи с лишним тысяч и всего приняла почти сто тысяч заказов. Росла она так, как растут все: оформление заказов написали в первый год на коленке, платежи прикрутили отдельным сервисом, когда появилась рассрочка, отзывы - ещё позже и под давлением продавцов. Каждая подсистема хранила данные по-своему, а договариваться между собой им было некогда.



Как устроена *Capibara*

- Площадка сводит продавцов и покупателей;
- Продавец размещает карточку товара;
- Покупатель оформляет заказ, в который может попасть несколько товаров, в том числе от разных продавцов;
- Каждый продавец отгружает свою часть заказа сам, у него есть крайний срок отгрузки;
- Дальше заказ едет к покупателю, и площадка фиксирует моменты передачи в доставку и вручения;
- После получения покупатель может оставить отзыв.

Задание

Вы — **архитектор данных Capibara**. Данные копились всё это время, но до сих пор лежат как есть: восемь выгрузок, которые никто не приводил в порядок. Аналитики не могут на них работать, т.к. каждый отчёт приходится собирать заново и каждый раз получаются разные цифры.

Главная задача

Спроектировать модель данных, на которую аналитики смогут опереться



Что это *значит?*

Сырые данные менять нельзя	Схема `raw` — то, что приехало от систем-источников. Вы строите свою модель в схеме core, наполняя её из `raw`.
Ответы должны считаться из вашей модели	Запрос напрямую к `raw` может дать верную цифру, но ничего не говорит о модели.
Решения придётся объяснить	Модель, которую никто в команде не может объяснить, оценивается низко, даже если цифры сошлись.

Что сдавать?

Схема и код

SQL-скрипт, который собирает вашу модель из **raw** с нуля

Ответы на вопросы

Запросы, которые вам будут предложены в начале и середине хакатона

Короткая записка о решениях

Не более, чем на полстраницы: что вы выбрали, от чего отказались и почему

Концепция дашборда

Творческая часть: собирать дашборд не нужно, нужно его описать



Стратегия развития

Куда модель растёт дальше

Важно *про данные*

Выгрузка настоящая, не учебный пример. Это открытые данные бразильского маркетплейса Olist за период с сентября 2016 по октябрь 2018 года, обезличенные: идентификаторы заменены на случайные строки, персональных сведений в них нет. Отсюда и португальские названия категорий, и бразильские штаты в адресах, и префикс `olist_` в именах файлов. В выгрузке есть пропуски, несостыковки и неочевидные места — ровно то, с чем работает инженер данных.

Разобраться в них — часть задания.

✱ Всего около 550 тысяч строк в восьми файлах.

Как оцениваем?

1 этап. Правильность ответов	10 вопросов (5 вначале, 5 в середине хакатона). **Максимум 30 баллов**
2 этап. Качество модели	• Гранулярность фактов • Работа с ключами • Пропуски и статусы • Структура и наполнение справочников **Максимум 30 баллов**
3 этап. Поддерживаемость	• Воспроизводимость сборки • Единообразие • Самопроверки • Прозрачность решений **Максимум 15 баллов**
4 этап. Понимание	• Реакция на вброс • Ответы на вопросы защиты **Максимум 25 баллов**

Как оцениваем?

5 этап. Концепция дашборда

- Область и вопросы дашборда
- Показатели и их источник
- Срезы и неаддитивные показатели
- Форма и границы

Максимум 20 баллов

6 этап. Использование ИИ

- Прозрачность использования ИИ
- Проверка выданного результата
- Собственные решения

Максимум 15 баллов

7 этап. Стратегия развития решения

- Развитие логической структуры
- Узкие места при росте
- Технологический стек
- Этапность и риски перехода

Максимум 20 баллов

Дальше на github.com